

한국 주식 가치평가 서비스

통합 설계 명세서

Version 2.0

— 설계·데이터·플로우·이론적 근거 —

발행일: 2026-05-19

KPMG Future Academy 8기 — 3차 팀 프로젝트

v1.0 (아모레퍼시픽 POC + Forward DCF) → v2.0 (전종목 + Three Anchors)

목차

장	제목
1	Executive Summary — 한 페이지 요약
2	서비스 비전 & 사용 시나리오
3	시스템 아키텍처
4	핵심 설계 결정사항 (Why & How)
5	Tab 2 — 정량 가치평가 (핵심)
6	Tab 3 — AI 내러티브 (정성 분석)
7	데이터 명세
8	임베딩 파이프라인 (상세)
9	피어 산정 (자동)
10	서비스 플로우 (Step by Step)
11	이론적 근거 & 학술적 타당성
12	우리가 고민한 Trade-offs
13	기술 스택 & 환경
14	현재 진행 상황 & 향후 계획
15	부록 — 산식·환경변수·명령어

1. Executive Summary

본 시스템은 일반 투자자가 종목명 또는 6자리 티커를 입력하면, 정량적 가치평가 (Tab 2) 와 정성적 AI 내러티브 (Tab 3) 를 한 화면에서 제공받을 수 있는 통합 분석 도구다. KOSPI-KOSDAQ 전 상장사 (약 2,600여 종목) 를 대상으로 한다.

1.1 v1.0 → v2.0 핵심 변경사항

항목	v1.0 (2026.04)	v2.0 (2026.05, 현재)
대상	아모레퍼시픽 1개사 POC	KOSPI+KOSDAQ 전 종목 (사용자 입력)
방법론	Forward DCF (FCFF 5년 + TV)	Three Anchors + WACC Threshold
가정 개수	22개 (정상화·Fade-out·g 등)	2개 (NOPAT 5년 중위값 + 피어 멀티플)
표본기간	3년 (FY2023~FY2025)	5년 (FY2021~FY2025)
ERP	8.0% 고정	신뢰구간 7~9% (low/mid/high)
출력 화면	1개 (Streamlit 대시보드)	3개 탭 (개요·정량·AI)
AI 활용	RAG (주식수·신용등급 추출만)	RAG + 챗봇 + 사건분류 + 정성해석
피어 선정	수동 (config 하드코딩)	자동 (사업보고서 RAG)
산업 대응	화장품 1개 산업	5개 산업 보편 지표 검증 완료

1.2 핵심 차별점

- 가정 최소화: 22 → 2개. 결과의 정밀성을 가정의 누적변동성이 가리지 않음.
- 음수 NOPAT 회사도 평가: Forward DCF 의 결정적 한계 (사이클 산업, 일회성 손실) 우회. Recovery Years 지표로 "얼마나 회복돼야 현 시총 정당화?" 답변.
- WACC 다각 활용: 단순 할인율(1) → EP·CP·Gap·Recovery(4). 같은 WACC 가 4가지 질문에 답.
- 가치 백스톱 3종: 자산(P/B)·매출(EV/Sales)·이익(NOPAT/WACC) 3차원 범위 → 단일 숫자 신뢰성 한계 보완.
- 산업 무관 보편 지표: 건설·IT·제약·금융·음식 5개 산업 표본 검증. 산업별 분기 로직 없음.
- AI 정성 분석: 사업보고서 챗봇 + 사건분류 RAG + 정성해석 — 정량 결과의 "맥락" 제공.

1.3 사용자 입력 → 결과 흐름 (1줄 요약)

"현대건설" 또는 "000720"

→ 자동: 피어 선정 (RAG) → XBRL 5년 재무 → WACC 신뢰구간 → Three Anchors → 4지표 → 멀티플 → 사이클 → AI 내러티브

→ 출력: 3개 탭 + 단일 통합 JSON

2. 서비스 비전 & 사용 시나리오

2.1 누구를 위한 서비스인가

본 서비스는 전문 분석가가 아닌 일반 투자자 를 1차 대상으로 한다. 구체적으로:

- 주식 투자를 시작했거나 검토 중이지만 DCF·WACC·멀티플 등 정량 도구에 자신이 없는 사람
- 공시·사업보고서를 읽는 시간은 부족하지만 "이 회사가 지금 비싼가 싼가" 답이 필요한 사람
- 재무 데이터에 대한 일반적 이해는 있되, 가정 22개를 직접 세팅할 수는 없는 사람
- 산업·기업 분석가의 보고서를 보조 도구로 활용하고 싶은 중급 투자자

따라서 본 시스템은 "이해 가능한 결정 보조" 를 우선한다. 정밀해 보이는 단일 숫자보다 범위·여러 anchor·맥락 (정성) 을 제공한다.

2.2 무엇을 해결하는가

일반 투자자의 Pain	본 서비스 해결책
DCF 의 "22개 가정" 부담 — 모르면 못 함	가정 2개 (NOPAT 5년 중위값 + 피어 멀티플) 로 자동화
음수 이익 회사 평가 불가 (Forward DCF 한계)	Three Anchors (자산·매출 백스톱) + Recovery Years
적정주가 "하나의 숫자" 가 신뢰가 안 감	WACC 신뢰구간 + Anchor 3종 범위 = 3차원 가치 구간
사업보고서 200~500쪽 읽기 부담	Tab 3 챗봇 → 자유 질문으로 핵심만 추출
멀티플 1개 (PER 등) 만 보면 산업 왜곡	4종 멀티플 + 피어 25~75 백분위 이격 경고
사이클 산업의 적자 연도 해석 불가	Tab 3 사건분류 RAG: "일회성 vs 구조적" 자동 판단
WACC 가 무엇인지·왜 쓰는지 모름	WACC Threshold 4지표 = 같은 WACC 가 4가지 질문에 답

2.3 사용자 입력 → 출력 흐름

2.3.1 입력

사용자는 다음 중 하나를 입력한다:

- 6자리 티커: "000720", "003230"
- 회사명: "현대건설", "삼양식품", "한올바이오파마"
- 회사명 + 주식종류 suffix: "현대건설보통주" → 자동 정규화
- 부분 매칭: "현대건" → "현대건설" 후보 5개 제시

입력 정규화는 `ticker_lookup.lookup()` 가 담당. 유니코드 정규화 + 공백·하이픈 제거 + 주식종류 suffix 제거 후 사업보고서 청크 파일명과 매칭.

2.3.2 출력 — 3개 탭

탭	주제	주요 기능	데이터 출처
Tab 1	회사 개요	재무 요약, 공시, 뉴스, 가격/시총 히스토리	팀원 영역 — XBRL 요약, DART 공시, 외부 뉴스, KRX 가격
Tab 2	정량 가치평가	WACC, Three Anchors, 4지표, 멀티플, 사이클, Peer Map	XBRL + KRX + ECOS + KOFIA + 사업보고서 RAG
Tab 3	AI 내러티브	사업보고서 챗봇, 사건분류, 정성해석	BGE-M3 + ChromaDB + GPT-4o-mini

2.4 사용 시나리오 (예시)

시나리오 A — 호기심 검증: "현대건설이 요즘 싸 보이는데 정말 그런가?"

- Tab 2 진입 → Three Anchors 가 "시총 5조원 vs Asset Anchor 9조원" → 75% 저평가 신호
 - WACC Threshold EP = +1,500억원 → 가치 창출 중
 - Cycle z-score = -1.2 → 건설 사이클 침체 국면 (멀티플 일시적 압축)
 - Recovery Years = 3.5년 → 정상 수익력 회복 시 시총 정당화 가능
 - Tab 3 챗봇: "FY2024 적자 원인이 일회성인가?" → "해외 공사손실 총당금 일회성" 답변
- 결론 도출 시간: 5분 (기존: 사업보고서·DCF 작성 30분~수 시간).

시나리오 B — 적자 회사 평가: "한올바이오파마 적자인데 평가 가능?"

- NOPAT 5년 중 4개 연도 적자 → Earnings Anchor 산출 불가
 - 그러나 Asset Anchor (장부가) + Revenue Anchor (피어 EV/Sales) 는 정상 산출
 - Recovery Years 지표: "정상 NOPAT 추정 500억원이면 7.2년 회복 → 장기 가능"
 - Tab 3: "파이프라인 임상 단계는?" → 사업보고서 RAG 로 자동 요약
- 적자 회사도 백스톱 가치 + 회복 시나리오로 의미 있는 평가 가능.

3. 시스템 아키텍처

3.1 패키지 구조 (디렉토리 트리)

```

VAR/
├──
├── peer_beta/
│   ├── beta_calculator.py
│   ├── krx_client.py
│   ├── calendar_utils.py
│   ├── config.py
│   ├── run_beta.py
│   └── data/
├──
├── valuation_engine/
│   ├── config.py
│   ├── ticker_lookup.py
│   ├── fetch_peers_financials.py
│   ├── compute_equity.py
│   ├── fetch_credit_rating.py
│   ├── ecos_client.py
│   ├── kd_loader.py
│   ├── cp_yield_data.py
│   ├── cp_to_bond_converter.py
│   ├── wacc_engine.py
│   ├── three_anchors.py
│   ├── wacc_threshold.py
│   ├── multiples_engine.py
│   ├── cycle_indicator.py
│   ├── peer_map.py
│   ├── run_valuation_v2.py
│   ├── streamlit_app.py
│   ├── tests/
│   └──
│       ├── rag_validation_cases.py
│       └── data/
├──
├── embedding/
│   ├── config.py
│   ├── chunk_loader.py
│   ├── embedder.py
│   ├── vector_store.py
│   ├── retrieval.py
│   ├── run_embed_all.py
│   ├── run_embed.ipynb
│   └── chroma_db/
├──
├── XBRL/
│   └── xbrl_financials_v4.py
├──
├── KOSPI/
├── KOSDAQ/
├──
└── docs/
    └── VAR_design_specification_v2.pdf

```

← **XXXX** **XX**

① **XX** **XX** **XX** **XX**
XX + Blume + Winsorize + Hamada
KRX OpenAPI **XX** (**XXXX**·**XXXX**)
XXXX/**XXXX** **XX**
XX **XX**·**XX** **XXXX** **XX**
XXXX
XX/**XX** **XX** + **XX** JSON

② **XX** **XXXX** (Tab 2)
FISCAL_YEARS, ERP **XXXX** **XX**
[NEW] **XXXX** **XX** **XXXX**
XBRL 5 **XX** **XX** **XX** (**XX** **XX** **XXXX**)
XXXX E (RAG + GPT-4o-mini)
XXXX RAG (**XXXX**/CP)
Rf (**XXXX** 10 **XX** **XXXX**)
KOFIA **XXXX** yield (5 **XX**, **XXXX**)
KOFIA CP yield (1 **XX**, **XXXX**)
CP → **XXXX** 5 **XX** **XX** **XX**
WACC + **XXXX** + Hamada
[NEW] Asset/Revenue/Earnings **XXXX**
[NEW] EP, CP, Gap, Recovery Years
4 **XX** **XXXX** **XX**
XX OPM 5 **XX** z-score
[NEW] 2D Peer Positioning Map
[NEW] Three Anchors **XX** **XXXX**
XXXX (v1 **XX**, v2 **XX** **XXXX**)

[NEW] **XXXX** **XX** (5 **XXXX**×10 **XXXX**)
xbrl/, equity/, wacc/, results/

③ RAG **XXXX** (Tab 3 + **XX**·**XX** **XXXX**)
XX·DB·**XXXX** **XX**
KOSPI/KOSDAQ jsonl **XX** + **XXXX**
BGE-M3 (transformers.AutoModel + FP16)
ChromaDB persistent
XXXXXX **XX** **XX**
XXXX **XX** **XXXX**
XXXX **XXXX** (**XXXX** **XXXX**)
ChromaDB **XX** **XXXX**

④ **XX** **XX** (DART XBRL → **XXXXXX**)
K-IFRS **XXXXXX** → JSON

⑤ **XXXXXX** **XX** jsonl (KOSPI)
⑥ **XXXXXX** **XX** jsonl (KOSDAQ)

⑦ **XX** **XX** (**XX** **XX** **XXXX**)

3.2 모듈 간 의존성

하위 모듈	사용처	역할
peer_beta	valuation_engine.wacc_engine, run_valuation_v2	주간 104주 (2년) 회귀 → Blume + Winsorize → Hamada Unlever 의 β_{L_adj} 제공
XBRL (팀원)	fetch_peers_financials	Rev/EBIT/D&A;/CapEx/NWC/IBD/NOA/한계세율 5년 시계열
embedding	compute_equity, fetch_credit_rating, Tab 3	사업보고서 청크 검색 (주식수·신용등급·정성 정보)
ecos_client	wacc_engine	Rf 실시간 (10년 국고채, ECOS API)
kd_loader/cp_*	wacc_engine, fetch_credit_rating	신용등급별 회사채 5년·CP 1년 yield (KOFIA CSV)
ticker_lookup	run_valuation_v2, Streamlit UI	사용자 입력 → (ticker, corp_name, market) 정규화
three_anchors	run_valuation_v2	Asset/Revenue/Earnings 3개 백스톱 통합 계산
wacc_threshold	run_valuation_v2	EP/CP/Gap/Recovery 4지표 (WACC 신뢰구간 각각)
peer_map	run_valuation_v2, Streamlit	타겟 + 피어 3사 (총 4점) 2D 산점도 데이터/figure
multiples_engine	run_valuation_v2	EV/Sales, EV/EBITDA, PER, PBR 역산 + 25~75 백분위
cycle_indicator	run_valuation_v2	타겟·피어 OPM 5년 → 산업 평균 z-score (호황/정상/침체)

3.3 환경 & 환경변수

변수명	용도	획득 방법
OPENAI_API_KEY	GPT-4o-mini (RAG 추출, 챗봇, 정성해석)	platform.openai.com → API keys
DART_API_KEY	DART OpenAPI (사업보고서·XBRL)	opendart.fss.or.kr → API 신청
krxdata	KRX OpenAPI (주가·지수, 소문자 키)	data.krx.co.kr → 회원가입·인증키
ECOS_API_KEY	한국은행 ECOS (Rf 10년 국고채)	ecos.bok.or.kr → 인증키 발급

conda 환경: dart-rag (Python 3.11.15)

4. 핵심 설계 결정사항 (Why & How)

4.1 Forward DCF 폐기 결정 (상세)

v1.0 의 핵심이었던 Forward DCF (FCFF 5년 명시예측 + Gordon Growth TV) 를 v2.0 에서 폐기했다. 폐기 사유는 검증 단계에서 발견된 다음 4가지 구조적 한계다.

4.1.1 음수 NOPAT 회사 문제

사이클 산업 (건설·해운·조선·반도체) 이나 일회성 손실 (회계 변경, 사업 정리) 이 발생한 회사는 과거 5년 중 적자 연도를 포함한다. Forward DCF 는 미래 FCFF 가 양수임을 전제로 하므로, 적자 연도를 "fade-out" 가정으로 미래 양수 전환을 강제해야 한다. 이 과정에서 추정자의 임의성이 결과의 신뢰도를 결정적으로 훼손한다.

실제 예: 현대건설 FY2024 영업적자 (해외 공사손실 총당금) → OPM 평균 -0.295% 로 끌어내림 → Y+1 EBIT 음수 → Fade-out 가정으로 Y+5 양수 강제 → 결과 비현실적.

4.1.2 NWC 점프 — 가공 현금 유입

Net Working Capital (NWC) 은 본질적으로 사이클성을 띤다. 건설처럼 수주·완공 타이밍이 들쭉날쭉한 산업은 NWC 가 연도별로 큰 폭으로 변동한다.

실제 예: 현대건설 NWC 가 FY2025 에 정상 1.99조 → 3.6조로 폭주. 1차 차이 $\Delta NWC = -1.6$ 조원 → FCFF 에 +1.6조 가공 현금 유입 → Y+1 FCFF 가 1.7조원 (시총의 30% 수준) 로 비현실적.

4.1.3 22개 가정의 누적 변동성

Forward DCF 5년 명시예측 + TV 는 다음 가정을 요구한다:

- Revenue 성장률 5년 × 1개 (CAGR 또는 Fade-out 패턴)
- OPM 1개 (정상화)
- D&A율 1개
- CapEx율 1개
- NWC율 1개
- Fade-out 계수 4개 (Y+1=CAGR, Y+2~Y+4=감소, Y+5=g)
- g (영구성장) 1개
- TV 가정 (Gordon vs Exit Multiple) 1개
- WACC 결정 6개 (R_f , β , ERP, SRP, CRP, K_d)
- 한계세율 갱신 5회

합계 약 22개. 각 가정에 $\pm 10\%$ 의 합리적 변동성을 부여하면, 결과 EV 의 신뢰구간이 본질적으로 $\pm 50\%$ 이상으로 벌어진다. 이는 "정밀해 보이는 단일 숫자" 라는 환상을 만들지만 실제 정보 가치는 낮다.

4.1.4 일반 투자자 목적적합성 부족

일반 투자자가 22개 가정을 모두 "이해하고 동의" 하기는 사실상 불가능하다. 결과적으로 사용자는 시스템이 제시한 단일 숫자를 "믿거나 의심하거나" 의 이항 선택을 강요받는다. 본 시스템의 목적 ("이해 가능한 결정 보조") 과 정면 충돌.

4.2 대체 — Three Anchors + WACC Threshold 채택

Forward DCF 의 4가지 한계를 모두 해결하는 프레임워크로 Three Anchors + WACC Threshold 를 채택했다.

4.2.1 핵심 변화

요소	Forward DCF (v1.0)	Three Anchors + WACC Threshold (v2.0)
가정 개수	22개	2개 (NOPAT 5년 중위값, 피어 멀티플)
적자 회사 평가	불가/임의적	가능 (Asset/Revenue Anchor + Recovery Years)
결과 형식	단일 적정주가 (1개 숫자)	3개 anchor 범위 + 4지표
WACC 활용	할인율 1회	EP-CP-Gap-Recovery 4지표
가정 추적가능성	낮음 (Fade-out 패턴)	높음 (NOPAT 시계열·피어 멀티플 분포 공개)
산업 보편성	사이클 산업에서 약함	5개 산업 표본 검증 완료

4.2.2 Three Anchors — 학술 토대

단일 DCF 가 아닌 여러 가치 벡스톱의 범위 를 제시하는 접근은 학술적으로 검증된 방법론이다.

- Aswath Damodaran (NYU Stern) — "Investment Valuation, 3rd ed." (2012) 에서 Asset-based, Earnings-based, Multiples-based 의 세 갈래 가치 추정을 권장. 본 시스템의 Three Anchors 는 이 framework 의 직접 구현.
- Benjamin Graham (The Intelligent Investor, 1949) — "안전마진 (Margin of Safety)" 개념. 단일 적정가격이 아닌 "가치 범위의 하단" 을 매수가의 기준으로. Asset Anchor 가 이 역할.
- Warren Buffett — "Owner Earnings" 정의: "정상화된 NOPAT 유지 CapEx". 본 시스템의 Earnings Anchor (NOPAT 5년 중위값 / WACC) 는 이 정신의 단순화.

4.2.3 WACC Threshold — 학술 토대

WACC 를 "단순 할인율" 이 아닌 "기준선/임계값" 으로 활용하는 접근:

- G. Bennett Stewart (Stern Stewart & Co., 1991) — Economic Value Added (EVA®) = (ROIC WACC) × Invested Capital. 본 시스템의 EP 지표 와 동일 산식.
- McKinsey & Co. (Valuation, 7th ed.) — "ROIC vs WACC 비교" 를 가치 창출 여부의 1차 진단으로 권장. Tab 2 의 EP 가 이 진단을 자동화.
- Capital Productivity (CP) 지표 — Damodaran 의 "Free Cash Flow to Firm 의 perpetual value" 와 동등 (성장 0% 가정). 시총과 직접 비교 가능한 단위로 환원.
- Recovery Years — 학술 명시 출처는 없으나 "DCF Recovery Period" 개념의 단순화. 음수 NOPAT 회사의 "턴어라운드 timing" 평가에 직관적.

4.3 표본기간 — 3년 → 5년

v1.0 의 3년 (FY2023~2025) 정상화는 사이클 효과를 흡수하기에 부족했다. v2.0 은 5년 (FY2021~2025) 으로 확장하여:

- 사이클 1주기 (한국 건설 ~3~4년) 의 평활화

- 중위값 NOPAT 의 outlier 견고성 ↑ (5개 중 2개 outlier 가능)
- WACC β 회귀 (104주, 2년) 와 표본기간 정합 (5년 표본 중 가장 최근 2년 주간 데이터)
- FY2021 = 코로나 회복 시점 포함 — 위기·정상화 모두 흡수

4.4 산업 다양성 — 보편 지표 채택

v2.0 검증 단계에서 5개 이질 산업 표본 의 사업보고서를 직접 점검했다:

산업	표본	특이사항
건설	현대건설 (000720)	사이클성 큼, 신용평가 AA-, 사업부문 도급/주택/플랜트 명확
IT/SaaS	더존비즈온 (012510)	Recurring revenue, NICE 만 신용평가, parse_mode=recover
제약	한올바이오파마 (009420)	신용평가 "해당사항 없음", R&D; 중심 (Earnings Anchor 약함)
금융	유진투자증권 (001200)	펀드 종속회사 수십개, 사업구조 복잡
음식	삼양식품 (003230)	사업부문 매출비중 명확, 신용평가 A0→A+ 상향

점검 결과 다음 원칙을 확정했다:

- 사업보고서 표준 섹션 구조 (I~XII) 가 산업 무관 일관 → BGE-M3 임베딩이 robust 처리.
- corp_name 표기 다양 ("현대건설보통주" vs "삼양식품") → 정규화 필수.
- 신용평가 미보유 회사 존재 → Tab 2 RAG 의 fallback 시나리오 (CP만 사용, 둘 다 없을 시 에러).
- 산업별 분기 로직 추가하지 않음 — Three Anchors + WACC Threshold 가 보편적으로 작동.
- 예외: 음수 NOPAT 회사 (제약·바이오) → Earnings Anchor 자동 None, Recovery Years 로 대체.

4.5 LLM 선택 — GPT-4o-mini

v1.0 (GPT-4o-mini) → Claude Haiku 4.5 (중간) → GPT-4o-mini (v2.0) 의 변천을 거쳤다.

최종 GPT-4o-mini 선택 사유:

- response_format=json_object 옵션으로 JSON 응답 강제 — 파싱 안정성 ↑
- temperature=0 + 명시적 스키마 → 결정론적 추출
- 한국어 사업보고서 표 (multi-row 신용평가 이력 등) 추출 정확도 안정적
- 비용 대비 효율 우수 (Tab 2 의 LLM 사용은 회사당 ~5회 호출)
- OpenAI Python SDK 1.40+ 안정 운영

4.6 임베딩 모델 — BGE-M3 + transformers AutoModel

임베딩 모델·라이브러리 선정에서 다음 trade-off 와 해결을 거쳤다 (상세는 8장).

- BGE-M3 (BAAI) 선택 — 한국어 retrieval SOTA, 1024 dim, 8K context, Apache 2.0 (무료)
- sentence-transformers 5.x 우회 → transformers.AutoModel 직접 사용 — sentence-transformers 가 datasets/aiohttp 끌어와 native SSL crash (Windows 0xC0000005) 유발
- FP16 on GPU — VRAM 절반·속도 2배. CPU 모드는 FP32 유지

- ChromaDB 영구 저장 — 메타데이터 필터 (ticker, year, section) 지원, ~192만 청크 안정 처리

5. Tab 2 — 정량 가치평가 (핵심)

Tab 2 는 본 시스템의 핵심 정량 분석 영역이다. 사용자 입력 종목에 대해 다음 6개 모듈이 순차 실행되어 통합 JSON 을 산출한다.

5.1 WACC 산출 (완전 상세)

$$WACC = E/V \times Re + D/V \times Kd \times (1 - \tau)$$

5.1.1 E — 보통주 시가총액

$$E = \text{T일 보통주 종가} \times (\text{보통주 발행주식수} - \text{자기주식수})$$

- 종가: KRX OpenAPI stk_stkprc_info_v1. peer_beta 모듈이 이미 캐시한 데이터 재사용 (추가 API 호출 0회).
- 주식수: 사업보고서 청크 RAG → GPT-4o-mini 추출. 사유: XBRL 재무제표는 주식 총수 정보 미포함 → 본문 표 ("I. 회사의 개요 > 4. 주식의 총수") 만 정보 보유.
- RAG 키워드: "주식의 총수", "발행주식", "자기주식", "유통주식", "보통주" 등 7개.
- JSON 스키마: common_issued, common_treasury, common_float.
- 안전장치: LLM 응답이 null 이거나 0 이하면 RuntimeError. 임의값 절대 금지.

코드: valuation_engine/compute_equity.py:fetch_shares_via_rag

5.1.2 β — 베타 (Hamada Unlever/Relever)

$$\beta_{L,target} = \beta_{U,med} \times [1 + (1 - \tau_{target}) \times (D/E)_{med}]$$

회귀 → Blume 조정 → Winsorize → Hamada Unlever 의 4단계로 산출:

- 회귀: 주간 104주 (2년) 수익률, OLS, KOSPI/KOSDAQ 종합지수 대비 (종목 시장 자동 매칭).
 $r_{stock} = \alpha + \beta \cdot r_{index} + \varepsilon$
- 주간 표본: 매주 금요일 종가 기준. 금요일 비영업일 → 직전 영업일 대체.
- Winsorize $\pm 3\sigma$: 표본 N 보존 (drop 아님). 일반 투자자에게 "N이 줄었다" 보다 "특이 사건 영향 제한" 이 설명 친화.
- Blume 조정: $\beta_{adj} = (2/3)\beta_{raw} + (1/3)1.0$. 이론적 근거: Blume (1971) — 베타의 시계열 평균회귀 (mean reversion) 실증 연구.
- Hamada Unlever: $\beta_{U,i} = \beta_{L,adj,i} / [1 + (1 - \tau_i) \times (D_i / E_i)]$. 각 피어의 자본구조 차이를 제거 → "순수 영업 위험" 만 남김.
- 피어 집계: β_U 중위값 + D/E 중위값 (산술평균 아님 — outlier 견고성 ↑).
- Hamada Relever: 타겟 자본구조로 β_L 재산정.

검증 기준: $R^2 \geq 0.10$, $|z| \leq 4.0$, missing weeks = 0

코드: peer_beta/beta_calculator.py + valuation_engine/wacc_engine.py

5.1.3 Re — 자기자본 비용

$$Re = Rf + \beta_{L,target} \times ERP + SRP + CRP$$

- Rf: ECOS API 10년 국고채 SPOT. T일 미공시 시 직전 영업일 (최대 7일).
- ERP: 신뢰구간 7~9% 사용 — 한공회 가이던스 권장범위. v1.0 의 8.0% 단일값 폐기.
- SRP: 시총 자동 매칭 (한공회 2025-06-10 3분위: Mid -0.36% / Low +1.37% / Micro +4.02%).
- CRP: 한국 단일시장 → 0% (POC).

5.1.4 Kd — 타인자본 비용

$$Kd_after_tax = Kd_raw \times (1 - \tau)$$

4단계 우선순위:

- 1단계: 사업보고서 RAG → GPT-4o-mini 가 회사채 + CP 신용등급 이력 동시 추출. 표 정렬 무관 모든 행 수집 → Python 측 날짜 내림차순 정렬 → 최신 1개 선택.
- 2단계: 회사채 등급 있음 → KOFIA CSV (회사채 I 공모사채 무보증 5년) 직접 매핑.
- 3단계: CP 등급만 있음 → "CP → 회사채 5년 등가 변환" 수행:

$$Kd = CP1\text{ yield} + (KOFIA\text{ 5년} - KOFIA\text{ CP1})$$
- 4단계: 둘 다 없음 → RuntimeError (임의값 금지).

CP → 회사채 신용등급 매핑 (한국 3대 신평사 표준):

CP 등급	회사채 매핑 등급
A1	AA-
A2+	A+
A2	A0
A2-	A-
A3+	BBB+
A3	BBB0
A3-	BBB-
B+~D 이하	BBB- (보수적 풀백)

5.1.5 WACC 신뢰구간 ($\beta U \sigma$ + ERP 7~9% 결합)

단순 ERP 만 변동시키는 것이 아니라 피어 βU 분산까지 결합한 보다 robust 한 신뢰구간:

- WACC_low (낙관): $\beta L = (\beta U_{med} - \sigma \beta U) \times \text{Relever}$, $Ke = Rf + \beta L \times \text{ERP_low}(7\%) + \text{SRP} + \text{CRP}$
- WACC_mid (중간): $\beta L = \beta U_{med} \times \text{Relever}$, $Ke = Rf + \beta L \times \text{ERP}(8\%) + \text{SRP} + \text{CRP}$
- WACC_high (보수): $\beta L = (\beta U_{med} + \sigma \beta U) \times \text{Relever}$, $Ke = Rf + \beta L \times \text{ERP_high}(9\%) + \text{SRP} + \text{CRP}$

$\sigma \beta U$ = 피어 βU 의 표준편차. 피어 분산이 클수록 신뢰구간이 넓어짐 (산업 동질성 신호).

이후 모든 지표 (EP, CP, Gap, Recovery, Anchors) 가 3 시나리오 각각에 대해 계산되어 사용자에게 범위로 제시.

5.2 Three Anchors — 3가지 가치 백스톱

핵심 원칙: 가정 2개 만으로 3차원 가치 범위 산출. (가정: NOPAT 5년 중위값 + 피어 멀티플 중위값)

5.2.1 NOPAT 정상화 — 5년 중위값

$$\text{NOPAT}_{\text{normalized}} = \text{median}(\text{NOPAT_FY2021}, \dots, \text{NOPAT_FY2025})$$

산술평균이 아닌 중위값 선택 사유:

- 한 해 특이 손실 (해외 공사손실 등) 의 영향을 자동 제거
- 사이클 산업의 호황·침체 양극단 outlier 견고성
- 5개 표본에서 2개까지 outlier 허용 (breakdown point = 0.4)

5.2.2 Asset Anchor — 장부 자산 기반

$$\text{Value}_{\text{asset}} = \text{Book Value} \times \text{Peer P/B (중위값)}$$

- Book Value: 최근 회계연도 자기자본 (XBRL equity)
- Peer P/B: 자동 선정된 피어 3사의 P/B 중위값. 25th / 75th 백분위 함께 산출 → 범위.
- 의미: "자산 가치 청산 시 기대 가치" — Graham 의 "Margin of Safety" 정신.

5.2.3 Revenue Anchor — 매출 기반

$$\text{Value}_{\text{revenue}} = (\text{Revenue} \times \text{Peer EV/Sales}) \quad \text{Net Debt}$$

- Revenue: 5년 중위값 (Revenue_5yr_median). 사이클 평활화.
- Peer EV/Sales: 동종업계 4사 중위값.
- Net Debt: IBD Cash (이중차감 방지 — v1.0 결정사항 #1 그대로).
- 의미: "매출 규모만으로도 정당화 되는 최소 가치".
- 특히 강력: 사이클 산업 (이익 변동 큼) 또는 적자 회사 (NOPAT 없음).

5.2.4 Earnings Anchor — 정상화 수익 자본환원

$$\text{Value}_{\text{earnings}} = (\text{NOPAT}_{\text{5yr_median}} / \text{WACC}) \quad \text{Net Debt}$$

- Gordon Growth 의 가장 보수적 형태 ($g = 0\%$).
- "정상 수익력을 영구히 유지" 가정 → 단순·검증 가능.
- 음수 NOPAT 시 None → Recovery Years 지표가 대체.
- WACC 신뢰구간 (low/mid/high) 각각에 대해 산출 → 범위.

5.2.5 Three Anchors 통합 출력

3개 anchor 의 mid 값 → min / max / range_ratio 산출. 사용자에게 "가치 범위" 를 시각적으로 제시.

코드: valuation_engine/three_anchors.py

5.3 WACC Threshold 4지표

같은 WACC 가 다음 4가지 질문에 답한다:

5.3.1 EP (Economic Profit) — "가치 창출 중인가?"

$$\text{EP} = (\text{ROIC} - \text{WACC}) \times \text{Invested Capital}$$

- $ROIC = NOPAT / Invested\ Capital$ (IC = Equity + Debt - Cash)
- Spread = ROIC - WACC (양수: 가치 창출, 음수: 파괴)
- Stern Stewart (1991) 의 EVA® 와 동일 산식.
- WACC 신뢰구간 각각에 대해 3개 EP 산출 → 보수적·중립·낙관 시나리오.

5.3.2 CP (Capital Productivity) — "수익을 자본 단위로 환원"

$$CP = NOPAT / WACC$$

- 정상 수익력을 "영구히 유지" 가정 시 가치 (성장 0%).
- 시총과 직접 비교 가능한 단위 → 시총/CP 비율로 저평가/프리미엄 자동 판단.
- Damodaran 의 "perpetual FCFF" 와 동등 (성장 가정 단순화).

5.3.3 Gap — "시장 프리미엄/디스카운트"

$$Gap\ (\%) = (EV - CP) / CP \times 100$$

- 양수: 시장이 정상수익 자본환원보다 프리미엄 부여 (성장·낙관 반영)
- 음수: 시장이 디스카운트 (위험·비관 반영)
- 투자자 직관: "이 회사에 시장이 얼마나 프리미엄을 주고 있는가?"

5.3.4 Recovery Years — "적자 회사 회복 timing"

$$EV = \sum_{t=1..T} \text{Normal NOPAT} / (1+WACC)^t$$

$$T = -\ln(1 - EV \cdot WACC / \text{Normal NOPAT}) / \ln(1 + WACC)$$

- 음수 NOPAT 회사 (Earnings Anchor 산출 불가) 에 대한 대체 지표.
- Normal NOPAT 추정 방법: 양수 연도만의 중위값, 또는 피어 OPM × Revenue.
- 결과 해석: T ≤ 5년 단기 회복 / 10년 중기 / 20년 장기 / 20년 초과 비현실적.
- 투자자 직관: "이 회사가 정상 수익력 회복하면 몇 년 만에 현 시총 정당화?"

코드: valuation_engine/wacc_threshold.py

5.4 멀티플 — 현재 3종 (PBR 보강 예정)

멀티플	산식	강점	상태
EV/Sales	EV / Revenue	사이클·적자 회사도 의미 있음 (NOPAT 음수 무관)	산출
EV/EBITDA	EV / (EBIT + D&A;)	감가상각 정책 차이 배제 → 운영 수익력	산출
PER	Price / EPS	주주 관점 직관적	산출
PBR	Price / BV	Asset Anchor 와 연동, 자산 기반 하한	△ N/A (자본총계 미수집 — 보강 예정)

각 멀티플: 피어 중위값 × 대상 분모 → 역산 가격. 피어 25~75 백분위 밖이면 "이격" 경고.

PBR 는 multiples_engine.py 에서 자본총계 미수집으로 None. 단, Asset Anchor (three_anchors.py) 는 별도로 BV × Peer P/B 직접 계산 — Asset 값은 정상 산출됨.

5.5 사이클 z-score — 산업 OPM 변동성

$$z = (\text{현재 OPM} - \text{산업 5년 평균 OPM}) / \text{산업 5년 표준편차 OPM}$$

- $z > +1$: 호황기 (멀티플 일시적 확장)
- $-1 \leq z \leq +1$: 정상기
- $z < -1$: 침체기 (멀티플 일시적 압축 — Three Anchors 대비 EV 저평가 가능)

결과를 한 줄 표시 → 멀티플·EP 해석의 보정 정보.

5.6 Peer Positioning Map — 2D 산점도

- X축: CP Score (NOPAT / WACC / Market Cap) — 클수록 저평가
- Y축: Earnings Yield (NOPAT / Market Cap × 100%) — 실질 수익률
- 4분면 해석: 우상단 (저평가+고수익, 매력적) / 좌하단 (고평가+저수익, 회피)
- 타깃을 빨간 별표로 강조, 피어 3사는 회색 원으로 표시 (총 4점)
- 피어 평균 가이드선 (X·Y 평균) 자동 그어짐

코드: valuation_engine/peer_map.py (Plotly)

6. Tab 3 — AI 내러티브 (정성 분석)

Tab 3 는 Tab 2 의 정량 결과에 맥락 (context) 을 제공한다. 사업보고서 본문에 묻혀 있는 정성 정보를 RAG + LLM 으로 자동 추출·해석한다.

6.1 사업보고서 챗봇

사용자 자유 질문 → BGE-M3 임베딩 → ChromaDB 검색 (타깃 회사 + 연도 필터) → GPT-4o-mini 답변 + 출처 인용.

6.1.1 흐름

- 사용자 질문 (예: "최근 5년간 해외 매출 비중 변화는?")
- `embed_query(question) → 1024 dim 벡터`
- `retrieve(query, ticker=..., year=..., top_k=10) → ChromaDB 검색`
- 상위 청크 컨텍스트 + 시스템 프롬프트로 GPT-4o-mini 호출
- 응답에 청크 ID, `section_path_str`, `corp_name` 자동 인용

6.1.2 출처 인용 정책 (환각 방지)

- LLM 응답에 반드시 "[청크 N, 섹션: ...]" 형식으로 출처 표기
- 검색된 청크 외 내용 추론 금지 (system prompt 에 명시)
- 추론 불가 시 "본문에 명시되어 있지 않습니다" 응답 강제

6.2 사건 분류 RAG — "일회성 vs 구조적"

Tab 2 에서 음수 NOPAT 연도가 발견되면 자동 트리거. 해당 연도 사업보고서 본문에서 키워드 RAG → LLM 분류.

- 키워드: "공사손실 총당금", "일회성 손실", "구조조정", "손상차손", "중단사업"
- LLM 출력: `{event_type, is_one_off, evidence_quote, confidence}`
- `is_one_off=True` → Three Anchors 의 NOPAT 시리즈에서 해당 연도 outlier 처리
- `is_one_off=False` → 구조적 변화, NOPAT 정상화 어려움 → 사용자에게 "평가 신뢰 낮음" 경고

6.3 정성 해석 — 정량 결과의 자연어 종합

Tab 2 의 모든 지표 (WACC, Three Anchors, EP/CP/Gap/Recovery, 사이클) 를 LLM 에게 입력 → 일반 투자자가 이해할 수 있는 한국어 문장으로 종합.

예시 출력:

"현대건설 은 ROIC(8.5%)가 WACC(7.2%) 보다 높아 가치를 창출 중입니다. Three Anchors 의 중위값은 약 7.8조원 (자산 9조, 매출 6.5조, 정상수익 7.8조) 로 현 시총 5조원 대비 56% 저평가 시그널입니다. 다만 산업 사이클 z-score = -1.2 로 침체 국면 이므로 멀티플의 일시적 압축이 반영된 결과일 수 있습니다. FY2024 영업적자는 [Tab 3 사건분류] 결과 ₩"해외 공사손실 총당금 일회성₩" 으로 분류되어 5년 NOPAT 중위값 산정에서 자동 제외되었습니다."

6.4 챗봇 답변 품질 검증

임베딩 완료 후 자동 검증 셋:

코드: `valuation_engine/tests/rag_validation_cases.py`

- 5개 산업 × 10 케이스 (사업부문·신용평가·주식수 등)
- 각 케이스 기대 키워드·기대 섹션 정의
- PASS / PARTIAL / FAIL 자동 채점
- 임베딩 완료 직후 ``python -m valuation_engine.tests.rag_validation_cases`` 1회 실행

7. 데이터 명세

7.1 외부 데이터 소스 (6종)

#	소스	용도	갱신 주기	인증
A-1	KRX OpenAPI	종가, 시가총액, 지수	영업일 자동	krxdata (소문자)
A-2	ECOS API	Rf (10년 국고채)	영업일 자동	ECOS_API_KEY
A-3	DART OpenAPI (XBRL)	재무수치 5년	사업보고서 공시 시 (수동)	DART_API_KEY
A-4	KOFIA 회사채 CSV	회사채 5년 yield (등급별)	사용자 수동	공개
A-5	KOFIA CP CSV	CP 1년 yield (등급별)	사용자 수동	공개
A-6	OpenAI API	GPT-4o-mini (RAG-챗봇-해석)	실시간	OPENAI_API_KEY

7.2 사업보고서 청크 jsonl 스키마

위치: VAR/KOSPI/<ticker>_<corp_name>_<year>_annual_chunks.jsonl (KOSDAQ 동일).

```
{
  "id": "000720-2025-annual-00010",
  "stock_code": "000720",
  "corp_name": "■■■■■■■■",
  "corp_code": "00164742",
  "report_kind": "2025-annual",
  "fiscal_period": "2025-annual",
  "rcept_no": "20260318000xxx",
  "rcept_dt": "20260318",
  "parse_mode": "strict",
  "kind": "table",
  "section_path": ["I. ■■■■ ■■", "1. ■■■■ ■■"],
  "section_path_str": "I. ■■■■ ■■ > 1. ■■■■ ■■",
  "char_len": 277,
  "text": "..."}

```

7.3 ChromaDB 임베딩 컬렉션

속성	값
컬렉션 명	annual_reports
저장 위치	VAR/embedding/chroma_db/
임베딩 모델	BAAI/bge-m3 (1024 dim, 8K context, Apache 2.0)
라이브러리	transformers.AutoModel (sentence-transformers 우회)
정밀도	GPU: FP16 / CPU: FP32
정규화	L2 (cosine = dot product)
대상 청크 수	약 192만 (KOSPI + KOSDAQ 전 종목)
전처리	corp_name 정규화, ID 중복 제거, v3 우선, 표지 청크 제외

7.4 ChromaDB 메타데이터 (13개 필드)

필드	타입	예시	용도
ticker	str	"000720"	회사 필터
corp_name	str	"현대건설"	정규화된 회사명
corp_name_raw	str	"현대건설보통주"	원본 (디버깅)
corp_code	str	"00164742"	DART 회사 식별자
year	int	2025	연도 필터
section_main	str	"I. 회사의 개요"	최상위 섹션 필터
section_sub	str	"1. 회사의 개요"	하위 섹션
section_path_str	str	전체 경로	출처 인용용
kind	str	"table" "text"	체크 유형
char_len	int	277	통계
rcept_no	str	"20260318..."	DART 접수번호
rcept_dt	str	"20260318"	접수일자
parse_mode	str	"strict" "recover"	XML 파싱 품질

7.5 산출물 JSON

파일	경로	내용
피어 베타	peer_beta/results/peer_beta.json	회사별 β_{raw} / β_{adjusted} / R^2 / N / α / residual_std / warnings
피어 재무 (XBRL)	valuation_engine/data/xbml/all_financials.json	회사·연도별 Rev/EBIT/D&A/CapEx/NWC/IBD/NOA/한계세율/NOPAT/FCFF
시가총액 E	valuation_engine/data/equity/peers_equity.json	회사별 종가·발행/자기주식·E_market_cap·RAG source/quote/confidence
WACC	valuation_engine/data/wacc/wacc_result.json	WACC_low/mid/high, β U/L, Re, Kd, D/V, 신용등급, KOFIA 매핑
가치평가 v2	valuation_engine/results/valuation_v2_.json	Three Anchors + 4지표 + 멀티플 + 사이클 + Peer Map 데이터 통합

7.6 데이터 흐름 다이어그램



7.7 단위·시각 규약

- 통화: 원(KRW). 표시 시 억/조 환산.
- 비율: 소수 (예: 0.04495 = 4.495%).
- 일자: ISO 형식 YYYY-MM-DD.
- 평가기준일 T: `date.today()` 자동.
- 회계연도: FY2021 ~ FY2025 (12월 결산 기준).

8. 임베딩 파이프라인 (상세)

Tab 3 RAG + Tab 2 의 주식수·신용등급·정성 추출의 토대인 사업보고서 임베딩.

8.1 모델 선정 — BGE-M3

- 모델: BAAI/bge-m3 (1024 dim, 8K context)
- 이유 1: 한국어 retrieval 벤치마크 (MIRACL-ko, KLUE) SOTA
- 이유 2: 8K context — 사업보고서 표·긴 청크 가능 (실제로는 max_length=512 로 안전)
- 이유 3: Apache 2.0 라이선스, 로컬 실행 (외부 API 호출 없음)
- 이유 4: dense + sparse + ColBERT 다중 표현 지원 (본 시스템은 dense 만 사용)

8.2 라이브러리 선정 — transformers.AutoModel

초기 (v1.0) 에는 FlagEmbedding 패키지 사용 → Windows 환경에서 native 충돌 (0xC0000005 ACCESS_VIOLATION) 발생. 이후 sentence-transformers 시도 → datasets/aiohttp 의존성이 native SSL 인증서 로드 단계에서 충돌. 최종 해결책: transformers.AutoModel 직접 사용 + CLS pooling + L2 normalize 수동 구현.

8.3 GPU FP16 — 메모리 절반·속도 2배

- GPU 가용 시 model.half() → FP16
- VRAM 사용량: FP32 ~2.3GB → FP16 ~1.2GB (RTX 4060 Laptop 8GB 에서 batch 64 안전)
- 최종 임베딩은 정밀도 안정성 위해 FP32 로 캐스팅 후 normalize

8.4 청크 전처리 (chunk_loader.py)

- 파일 dedupe: 같은 ticker 의 여러 버전 (예: _v3) 중 가장 최신 1개만 사용
- ID dedupe: jsonl 내부 ID 중복 (소스 파이프라인 버그) 자동 스킵
- 표지 청크 제외: section_main="(문서 본문)" 만 있는 청크 (제출 정보, 표지)
- 짧은 청크 제외: char_len < 30 → 의미 없는 fragment
- corp_name 정규화: "보통주/우선주/1우B/2우B" suffix 제거 → 검색 일관성
- parse_mode 메타: "strict" (정상) / "recover" (XML 파싱 에러 복구) → 디버깅 표시

8.5 ChromaDB 영구 저장 + 증분 업데이트

- PersistentClient: 파일시스템 영구 저장 (재시작 시 자동 로드)
- 증분 업데이트: get_existing_ids() 로 이미 임베딩된 ID 자동 스킵
- 중간 중단 안전: 도중에 끊겨도 다시 실행 시 이어서 진행
- --reset 옵션: 컬렉션 통째 초기화 (개발용, 주의)

8.6 임베딩 실행 옵션

CMD:

```
conda activate dart-rag
cd C:\Users\Admin\Desktop\VAR
python -m embedding.run_embed_all # KOSPI + KOSDAQ ■■■
python -m embedding.run_embed_all --market kospi # KOSPI ■
python -m embedding.run_embed_all --dry-run # ■■■ (■■ X)
python -m embedding.run_embed_all --batch-size 32 # OOM ■ ■■■
```

Jupyter:

VAR/embedding/run_embed.ipynb — 셀 단위 단계 실행, tqdm 진행률 시각화.

8.7 실측 성능 (RTX 4060 Laptop, 8.6GB VRAM)


설정	속도	192만 청크 ETA	GPU 사용
batch 16, max_len 1024, FP32	약 21 청크/sec	약 25시간	100% util, 84W TGP
batch 32, max_len 512, FP16	약 62 청크/sec	약 8.5시간	100% util, 84W TGP
batch 64, max_len 512, FP16	약 100~150 청크/sec (예상)	약 4~5시간	TGP 한계

노트북 GPU 의 TGP (Total Graphics Power) 85W 한계가 사실상 throughput 의 상한. FP16 + batch 키움으로 가용한 만큼 짜냄.

9. 피어 산정 (자동)

v1.0 에서는 config.py 에 타깃 (아모레퍼시픽) + 피어 3사 (LG생활건강·한국콜마·에이피알) 총 4사 하드코딩. v2.0 은 사용자 입력 종목에 따라 자동 산정.

9.1 자동 산정 흐름



9.2 사업부문 매칭 알고리즘 (구상)

- 타깃 사업부문 요약 (LLM): "건설업 - 도급공사, 주택사업, 플랜트, 인프라"
- 후보 사업부문 요약: 동일 절차로 KOSPI+KOSDAQ 약 2,600개 회사 처리
- 벡터 유사도: BGE-M3 임베딩 cosine similarity
- 점수 보정: 시가총액 ratio (0.3x~3x 가산), 산업 코드 일치 시 가산
- Top 4 피어 + 타깃 = 총 5사 처리

코드: valuation_engine/peer_selector.py (임베딩 완료 후 구현 예정)

9.3 사용자 입력 정규화 (ticker_lookup.py)

입력	처리	결과
"000720"	6자리 숫자 매칭	exact: 현대건설
"현대건설"	정규화 → 정확 매칭	exact: 000720
"현대건설보통주"	suffix 제거 → "현대건설" 매칭	exact: 000720
"현대건"	startswith 매칭	ambiguous: 현대건설, 현대건설기계 등
"999999"	매칭 실패	not_found

10.2 데이터 의존성 순서 (병렬 가능 여부)

#	단계	선행	병렬 가능	예상 시간
1	입력 정규화	(없음)	(단일)	< 1초
2	피어 자동 산정 (RAG)	1	X	5~10초
3a	Tab 1 (팀원 영역)	1	O (Tab 2 와 병렬)	5초
3b	XBRL 5년 재무	2	O	10초 (캐시 hit) / 1분 (miss)
3c	KRX 증가 (peer_beta 캐시)	2	O	1~5초 (캐시 hit)
3d	ECOS Rf	(없음)	O	1초
3e	사업보고서 RAG (주식수)	2	O	5~15초 (LLM)
3f	사업보고서 RAG (신용등급) + KOFIA	2	O	5~15초 (LLM)
3g	peer_beta 회귀 (104주)	3c	(직렬)	3~5초
4	WACC 신뢰구간	3a~3f	(병합)	1초
5	Three Anchors + 4지표 + 멀티플 + 사이클	4	(병합)	1초
6	Tab 3 사건 분류 (음수 NOPAT 시)	5	(조건)	5~10초
7	Tab 3 정성 해석	5	(병합)	5~10초
8	Streamlit 표시	3,4,5,6,7	(통합)	즉시

10.3 1회 분석 총 소요 시간 (예상)

- 전 캐시 hit (재분석): 약 30~45초 — RAG·LLM 응답 시간 위주
- 일부 miss (피어 1~2사 신규): 약 1~2분
- 전 miss (신규 회사): 약 2~3분 — XBRL 수집 포함

11. 이론적 근거 & 학술적 타당성

본 시스템은 "새로운 가치평가 이론" 을 제시하지 않는다. 기존 검증된 학술 도구·실무 표준을 일반 투자자 친화적으로 조합 한 것이다. 각 핵심 가정의 근거를 출처와 함께 정리한다.

11.1 Hamada Model (1972)

출처: Robert S. Hamada, "The Effect of the Firm's Capital Structure on the Systematic Risk of Common Stocks", Journal of Finance, May 1972.

- 핵심: β (체계적 위험) 는 영업 위험 + 재무 위험의 합. 자본구조 차이를 제거하면 "순수 영업 위험" 만 남음.
- 산식: $\beta_U = \beta_L / [1 + (1 - t) \times D/E]$
- 본 시스템 적용: 피어 3사 의 β 를 Unlever → 중위값 → 타깃 자본구조로 Relever.
- 전제: Modigliani-Miller (1958, 1963) 의 자본구조 무관성 가정 (세금 보정 포함).

11.2 Blume Adjustment (1971)

출처: Marshall E. Blume, "On the Assessment of Risk", Journal of Finance, March 1971.

- 실증 관찰: 시계열 베타가 평균 1.0 으로 회귀 (mean reversion) 하는 경향.
- 조정식: $\beta_{adj} = (2/3) \times \beta_{raw} + (1/3) \times 1.0$
- 2/3, 1/3 의 이론적 근거: 추정 β 의 표본 분산과 회귀 분산의 비율에서 도출된 최적 가중.
- 본 시스템 적용: 회귀 β → Blume 조정 후 Hamada Unlever 입력.
- 실무 표준: Bloomberg, KRX, 한공회 가이드스 모두 (2/3, 1/3) 사용.

11.3 Winsorization (1960s)

출처: Charles P. Winsor 의 robust statistics 방법론.

- 핵심: outlier 의 영향을 줄이되 표본 N 은 보존.
- 본 시스템: $\pm 3\sigma$ 원저화 — 평균 $\pm 3 \times$ 표준편차 밖의 값을 경계값으로 대체.
- 일반 투자자 친화: "N 이 줄었다" (drop) 보다 "특이 사건 영향을 $\pm 3\sigma$ 로 제한" 이 설명 친화.
- 대안 비교: Trimming (drop) → 표본 손실 큼. Median absolute deviation (MAD) → 표본 분포 가정 다름. $\pm 3\sigma$ 는 정규 분포 가정에서 99.7% 포괄, 실무 표준.

11.4 Gordon Growth Model 의 한계와 우회

출처: Myron J. Gordon, "Dividends, Earnings, and Stock Prices", Review of Economics and Statistics, May 1959.

- 핵심 공식: $V = D_1 / (r - g)$
- 한계: g (영구 성장률) 가정의 임의성, $r - g$ 분모 폭주 위험 ($r - g$ 시 발산), 단일 시점 추정의 시간 가변성 무시.

- v2.0 우회: Earnings Anchor = NOPAT / WACC 만 사용 ($g = 0\%$ 고정 — 가장 보수적).
- Trade-off: 성장성이 큰 회사는 저평가됨 → Revenue Anchor + 멀티플로 보완.
- 일반 투자자 친화: 임의 g 가정 제거로 결과 추적가능성 ↑.

11.5 Three Anchors 의 학술 토대

- Aswath Damodaran (NYU Stern) — "Investment Valuation, 3rd ed." (2012) — "valuation triangle": Asset-based, DCF, Relative valuation 세 갈래 권장.
- Benjamin Graham (1949) — "The Intelligent Investor" — Margin of Safety 개념. Asset Anchor 가 매수 하한선 역할.
- Warren Buffett (Berkshire Hathaway 1986 letter) — "Owner Earnings" 정의. Earnings Anchor 의 정신적 토대.
- 본 시스템 응용: 세 가지를 "동시에.범위로" 제시 — 일반 투자자가 단일 숫자 신뢰에 의존하지 않게.

11.6 EVA® (Economic Value Added)

출처: G. Bennett Stewart III (Stern Stewart & Co., 1991), "The Quest for Value".

- 산식: $EVA = (ROIC - WACC) \times \text{Invested Capital}$
- 본 시스템 EP 지표 = EVA 와 동일 산식.
- 해석: $ROIC > WACC \rightarrow$ 가치 창출. $ROIC < WACC \rightarrow$ 가치 파괴.
- McKinsey (Valuation, 7th ed.) — ROIC vs WACC 비교를 가치 진단의 1차 척도로 권장.

11.7 멀티플 25~75 백분위 이격

- 표준 실무: 피어 멀티플의 IQR (Interquartile Range) 밖이면 "산업 정상 범위 이탈".
- 일반 투자자 신호: 25th 이하 = 상대적 저평가, 75th 이상 = 프리미엄.
- 본 시스템: 4종 멀티플 모두 P25 ~ P75 표시 + 이탈 시 경고.

11.8 사이클 z-score

- 출처: 학술 명시 출처는 없으나 "산업 사이클 정상화" 의 일반적 통계 표현.
- 핵심: 현재 OPM 이 5년 평균 대비 몇 표준편차 떨어져 있는가 → 사이클 국면 진단.
- 응용: 침체기 ($z < -1$) 에는 멀티플이 일시적 압축 → "가치 백스톱 vs 시총" 의 격차가 진짜 저평가일 수 있음.

11.9 NWC·Cash·NOA 처리 (v1.0 결정사항 유지)

- 현금성자산: Net Debt 산정에서만 차감 ($\text{Net Debt} = \text{IBD} - \text{Cash}$). NOA 에서는 제외 → 이중차감 방지.
- NOA: 팀원 NOA_RULES_FINAL_V3 그대로 (확실/기본/조건부/OA/별도처리 5분류).

- NWC: Three Anchors 의 Earnings Anchor 에는 영향 없음 (NOPAT / WACC 만 사용). Forward DCF 폐기로 NWC 점프 문제 자체가 해소.

12. 우리가 고민한 Trade-offs

v2.0 설계 과정에서 결정 곤란을 야기한 trade-off 들과 우리의 선택·근거를 기록.

12.1 단일 숫자 vs 범위

고민: 일반 투자자는 단일 "적정주가" 를 기대. 그러나 가치평가의 본질은 범위.

결정: 범위로 제시 + 직관적 시각화 (Anchor 3개 + WACC 신뢰구간)

근거:

- v1.0 의 단일 적정주가가 "22개 가정" 의 함수임을 사용자가 알지 못함 → 과신 위험.
- v2.0 의 3개 anchor + WACC low/mid/high 는 결과의 본질적 불확실성을 시각화.
- 교육 효과: 사용자가 "가치는 점이 아닌 구간" 임을 자연스럽게 학습.

12.2 산업 특화 vs 보편 지표

고민: 건설은 NWC 점프, 제약은 R&D, 금융은 부채구조 — 산업별 특화 로직 필요?

결정: 보편 지표 채택 (산업별 분기 X)

근거:

- 5개 산업 표본 (건설·IT·제약·금융·음식) 점검 결과: Three Anchors + WACC Threshold 가 모두 작동.
- 산업별 특화 로직 = 코드 복잡도 ↑, 유지보수 부담 ↑, 산업 분류 의존성.
- 예외 처리는 자료 단계 (음수 NOPAT → Earnings Anchor None → Recovery Years 대체).
- 다양한 산업 비교가능성 유지 — 일반 투자자가 산업 간 직접 비교 가능.

12.3 결정론적 vs 시나리오/Monte Carlo

고민: v1.0 의 Bear/Base/Bull 시나리오 + Monte Carlo 도입 검토?

결정: 결정론적 (재현 가능) + ERP 신뢰구간 7~9% 만 활용

근거:

- Bear/Base/Bull 의 각 케이스 자체가 "여러 가정" — 일반 투자자가 추적 불가.
- Monte Carlo → 가정 분포 자체가 추정이라 "가짜 정밀성" 위험.
- WACC 신뢰구간 (ERP 7~9%) 만으로도 핵심 불확실성 표현 가능.
- 재현가능성: 같은 입력 → 같은 결과 (디버깅·검증·신뢰 확보).

12.4 자동 vs 수동 가정

고민: 일부 가정 (예: 영구성장률 g) 을 사용자가 조정 가능하게?

결정: 완전 자동 (사용자 입력은 종목명만)

근거:

- 일반 투자자가 g, OPM 정상화 등의 적정값을 결정할 수 없음.

- 자동화 = 결과의 재현가능성, 디버깅 용이성.
- 단, 출력에는 "이 결과에 사용된 모든 가정" 을 투명하게 표시 (5년 NOPAT 시계열, 피어 멀티플 분포).

12.5 임의값 vs 명시적 에러

고민: 데이터 부재 (신용평가 없음, 주식수 추출 실패 등) 시 fallback?

결정: 임의값 절대 금지 — RuntimeError 발생

근거:

- 임의 fallback 값이 "정확값" 으로 표시되면 사용자 신뢰도 회복 불가.
- 에러 발생 = 사용자가 "이 회사는 이 시점 평가 불가" 임을 명확히 인식.
- 예외: 회사채 등급 없으면 CP 등급으로 변환 (검증된 변환식이므로 "임의" 가 아님).

12.6 LLM 모델 선택 (Claude vs GPT)

고민: Claude Haiku 4.5 vs GPT-4o-mini — 한국어 사업보고서 추출에 어느 것?

결정: GPT-4o-mini

근거:

- GPT-4o-mini 의 response_format=json_object 옵션이 JSON 파싱 안정성 ↑
- Claude 의 "assistant prefill" 기법 ("{" 로 시작 강제) 대비 OpenAI API 가 직관적.
- 한국어 사업보고서 표 추출 정확도는 양쪽 비슷 (실제 측정).
- OpenAI SDK 1.40+ Windows 환경에서 안정 운영 확인.
- Trade-off: Claude 가 일부 케이스에서 추론력 더 좋지만, 본 시스템은 "추출 (정보 옮기기)" 가 주 → GPT 충분.

12.7 임베딩 모델 선택 (FlagEmbedding vs sentence-transformers vs AutoModel)

고민: BGE-M3 를 어떤 라이브러리로 로드?

결정: transformers.AutoModel 직접 사용 + CLS pooling 수동 구현

근거:

- FlagEmbedding: BGE 공식 라이브러리이나 Windows 에서 native crash (0xC0000005).
- sentence-transformers: datasets/aiohttp 의존성이 native SSL crash 유발.
- transformers.AutoModel: 최소 의존성, Windows-CUDA 안정 작동.
- 비용: CLS pooling + L2 normalize 를 직접 코드해야 하지만 (sentence-transformers 가 자동 처리) 수습 줄에 불과.

12.8 FP16 vs FP32

고민: BGE-M3 inference 정밀도?

결정: GPU 면 FP16, CPU 면 FP32. 최종 임베딩은 FP32 로 캐스팅 후 정규화

근거:

- FP16: VRAM 절반, 속도 2배 (배치 키울 수 있음).
- BGE-M3: 학습 시 mixed precision 사용 → FP16 안전.
- 최종 캐스팅: ChromaDB 저장 시 float32 라야 호환 + 정밀도 안정.
- 실측: FP16 vs FP32 retrieval recall@10 차이 $\leq 0.5\%$ — 무시 가능.

12.9 ChromaDB vs FAISS vs Pinecone

고민: 벡터 DB 선택?

결정: ChromaDB

근거:

- ChromaDB: PersistentClient + 메타데이터 필터 (ticker, year, section) 완벽 지원.
- FAISS: 빠르지만 메타데이터 필터 별도 구현 필요 — 코드 부담.
- Pinecone: 외부 서비스, 비용 발생 (192만 청크 호스팅 부담).
- 본 규모 (192만 청크) 에서 ChromaDB 성능 충분 (검색 ~100ms).

13. 기술 스택 & 환경

13.1 언어 & 환경

- Python 3.11.15 (conda dart-rag)
- OS: Windows 10/11 x64
- GPU: NVIDIA RTX 4060 Laptop (8GB VRAM, CUDA 12.x)
- RAM: 16GB+

13.2 핵심 라이브러리

영역	라이브러리	버전	용도
가치평가	pandas	>= 2.0	데이터 프레임
	numpy	>= 1.24	수치 계산
	statsmodels	>= 0.14	OLS 회귀 (β)
임베딩	transformers	>= 4.40, < 5.0	AutoModel
	tokenizers	0.21.x	BGE-M3 tokenizer
	torch	>= 2.0 + cu12x	PyTorch GPU
벡터 DB	chromadb	>= 1.5	PersistentClient
LLM	openai	>= 1.40	GPT-4o-mini SDK
UI	streamlit	>= 1.30	통합 UI
	plotly	>= 5.18	Peer Map 2D
문서	reportlab	>= 4.0	PDF 생성
진행률	tqdm	>= 4.65	임베딩 진행 표시
네트워크	requests	>= 2.31	API 호출
	python-dotenv	>= 1.0	.env 로드

13.3 환경 의존성 충돌 해결 사례

환경 점검 단계에서 다음 충돌을 발견·해결:

사례	원인	해결
transformers 5.x 와 FlagEmbedding 비호환	FlagEmbedding 이 transformers 4.x 시대 API 사용	transformers < 5.0 로 다운그레이드 + FlagEmbedding 제거
sentence-transformers 5.x → datasets 끌어와 SSL crash	Windows native SSL 인증서 로드 충돌	transformers.AutoModel 직접 사용으로 우회
numpy 2.x 와 일부 native lib ABI 충돌 가능성	numpy 2.x ABI breaking change	현재는 numpy 2.4.3 사용 (충돌 미발생). 발생 시 numpy < 2.0 다운그레이드

사례	원인	해결
GPU OOM (RTX 4060 Laptop 8GB)	batch 32 × max_length 8192 + FP32 → 메모리 폭주	FP16 + batch 64 + max_length 512 로 안정 구간
커널 silent crash (0xC0000005)	GPU CUDA context stuck (이전 프로세스 정리 안 됨)	OS 재부팅으로 CUDA context 리셋

14. 현재 진행 상황 & 향후 계획

14.1 모듈 완성도 (2026.05.19 기준)

영역	모듈	상태	비고
데이터 수집	peer_beta	완료	β + Blume + Winsorize + Hamada
	valuation_engine/fetch_peers	완료	XBRL 5년 호출 (팀원 모듈)
	compute_equity	완료	E (RAG + GPT-4o-mini)
	fetch_credit_rating	완료	신용등급 (RAG + GPT-4o-mini)
	ecos_client / kd_loader / cp_*	완료	Rf + Kd
	ticker_lookup	완료	사용자 입력 정규화 [NEW]
가치평가	wacc_engine	완료	WACC 신뢰구간
	three_anchors	완료	Asset/Revenue/Earnings [NEW]
	wacc_threshold	완료	EP/CP/Gap/Recovery [NEW]
	multiples_engine	완료	4종 멀티플
	cycle_indicator	완료	산업 OPM z-score
	peer_map	완료	2D Plotly Map [NEW]
	run_valuation_v2	완료	Three Anchors 통합 진입점 [NEW]
임베딩	embedding 패키지	완료	BGE-M3 + ChromaDB
	임베딩 실행	진행 중	192만 청크, ETA ~8시간
검증	tests/rag_validation_cases	완료	5산업×10케이스 [NEW]
피어 자동	peer_selector	대기	임베딩 완료 후 구현
Tab 3	chatbot / event_classify / narrative	대기	임베딩 완료 후 구현
UI	streamlit_app v2 통합	대기	Three Anchors 표시 추가
문서	PDF v1.0	완료	VAR_design_specification_v1.pdf
	PDF v2.0 (본 문서)	완료	통합 명세서

14.2 단기 계획 (임베딩 완료 직후)

- RAG 검증 실행 — `python -m valuation_engine.tests.rag_validation_cases`
- Three Anchors 단일 종목 실행 — `python -m valuation_engine.run_valuation_v2 --ticker 000720`
- 결과 JSON 점검 + 수치 sanity check
- Peer Selector 모듈 신규 (사업보고서 RAG 기반 자동 피어 선정)

14.3 중기 계획 (Tab 3 + Streamlit)

- Tab 3 chatbot.py — 사업보고서 챗봇 (출처 인용 포함)
- Tab 3 event_classify.py — 음수 NOPAT 일회성 자동 분류
- Tab 3 narrative.py — Tab 2 결과 자연어 종합 해석
- streamlit_app.py 보강 — Three Anchors / 4지표 / Peer Map / Tab 3 표시 추가
- 캐싱 강화 — 동일 종목 재조회 시 즉시 응답 (5분 TTL)

14.4 장기 계획 (확장)

- 분기보고서·반기보고서 임베딩 추가 (현재는 사업보고서만)
- 주요 공시 임베딩 (정정공시, 분기 가이드스)
- 다국적 비교 (해외 동종업계 멀티플 — Bloomberg / Yahoo Finance)
- 사용자별 관심종목·시나리오 저장
- API 서비스화 (REST API)
- 모바일 UI

15. 부록

15.1 핵심 산식 모음

E (보통주 시가총액)

$$E = \text{종가} \times (\text{보통주 발행수} - \text{자기주식수})$$

β Blume 조정

$$\beta_{\text{adj}} = (2/3) \times \beta_{\text{raw}} + (1/3) \times 1.0$$

Hamada Unlever

$$\beta_U = \beta_L / [1 + (1 - t) \times D/E]$$

Hamada Relever

$$\beta_{L,\text{target}} = \beta_{U,\text{med}} \times [1 + (1 - t_{\text{target}}) \times (D/E)_{\text{med}}]$$

Re (자기자본 비용)

$$Re = R_f + \beta_{L,\text{target}} \times ERP + SRP + CRP$$

Kd (CP → 회사채 변환)

$$Kd = \text{CP1년} + (\text{회사채5년 매핑등급} - \text{CP1년 원등급})$$

WACC

$$WACC = E/V \times Re + D/V \times Kd \times (1 - \tau)$$

NOPAT 정상화

$$\text{NOPAT}_{\text{norm}} = \text{median}(\text{NOPAT}_{\text{FY2021}}, \dots, \text{NOPAT}_{\text{FY2025}})$$

Asset Anchor

$$V_{\text{asset}} = BV \times \text{Peer P/B (중위값)}$$

Revenue Anchor

$$V_{\text{rev}} = (\text{Revenue} \times \text{Peer EV/Sales}) - \text{Net Debt}$$

Earnings Anchor

$$V_{\text{earn}} = (\text{NOPAT}_{\text{norm}} / WACC) - \text{Net Debt}$$

EP (Economic Profit)

$$EP = (ROIC - WACC) \times \text{Invested Capital}$$

CP (Capital Productivity)

$$CP = \text{NOPAT}_{\text{norm}} / WACC$$

Gap

$$\text{Gap} = (EV - CP) / CP \times 100$$

Recovery Years

$$T = \ln(1 - EV \cdot WACC / \text{Normal NOPAT}) / \ln(1 + WACC)$$

Cycle z-score

$$z = (\text{현 OPM} - 5\text{년 평균}) / 5\text{년 } \sigma$$

Peer Map X / Y

$$X = \text{NOPAT} / (WACC \times \text{MarketCap}), Y = \text{NOPAT} / \text{MarketCap} \times 100$$

15.2 환경변수 (.env)

```
OPENAI_API_KEY=...      # GPT-4o-mini
DART_API_KEY=...        # DART OpenAPI (XBRL)
krxdata=...             # KRX OpenAPI (■■■■ - ■■■■ ■■)
ECOS_API_KEY=...        # ■■■■ ECOS
```

15.3 명령어 cheat sheet

```
# ■■
conda activate dart-rag
cd C:\Users\Admin\Desktop\VAR

# ■■■■ (KOSPI + KOSDAQ ■■)
python -m embedding.run_embed_all
python -m embedding.run_embed_all --market kospi
python -m embedding.run_embed_all --dry-run
python -m embedding.run_embed_all --batch-size 32

# ■■■■ ■■
python -m valuation_engine.tests.rag_validation_cases

# ■■■■ (Three Anchors)
python -m valuation_engine.run_valuation_v2 --ticker 000720

# Streamlit ■■■■
streamlit run valuation_engine\streamlit_app.py

# ■■ ■■ ■■ ■■
python -m valuation_engine.three_anchors
python -m valuation_engine.wacc_threshold
python -m valuation_engine.peer_map
python -m valuation_engine.ticker_lookup

# PDF ■■
python generate_design_doc_v2.py
```

15.4 용어 사전

용어	정의
NOPAT	Net Operating Profit After Tax — 세후 영업이익. $EBIT \times (1 - t)$.
WACC	Weighted Average Cost of Capital — 가중평균 자본비용.
EP/EVA	Economic Profit / Economic Value Added — $(ROIC - WACC) \times IC$.
ROIC	Return on Invested Capital — $NOPAT / Invested\ Capital$.
IC	Invested Capital — $Equity + IBD - Cash$.
IBD	Interest-Bearing Debt — 단기차입금+장기차입금+사채+리스부채.
NOA	Non-Operating Assets — 영업외 자산 (투자부동산 등). 팀원 5분류.
FCFF	Free Cash Flow to Firm. v2.0 폐기 (Forward DCF 폐기 결과).
ERP	Equity Risk Premium — 시장위험프리미엄. v2.0 은 7~9% 신뢰구간.
SRP	Size Risk Premium — 규모위험프리미엄. 한공회 3분위 자동 매칭.
CRP	Country Risk Premium — 국가위험프리미엄. 한국 0%.
KOFIA	금융투자협회 — 채권/CP 시가평가 수익률 공시.
KRX	한국거래소 — 주가·지수 OpenAPI 제공.
ECOS	한국은행 경제통계시스템 — Rf (국고채) 등 거시지표.
DART	전자공시시스템 — 사업보고서·XBRL 재무제표.
XBRL	eXtensible Business Reporting Language — 표준화된 재무제표 형식.
BGE-M3	BAAI General Embedding M3 — 한국어 retrieval SOTA 모델.
RAG	Retrieval-Augmented Generation — 검색+LLM 결합 추출/응답.

— 문서 끝 —